

E-Commerce Clickstream Analytics: High-Performance Data Pipeline & Dashboard

Arsitektur Modern Data Stack Lokal untuk Manajemen Big Data Skala 110 Juta+ Baris

Developer: Daffa Farros Azhari
Peran: Data Analyst & Automation Specialist

Skala Data: 14 Gigabyte (GB)
Volume: 110.000.000+ Baris Operasi

DuckDB Polars (Rust Engine) Streamlit Plotly Interaktif


1. Ringkasan Eksekutif (Project Overview)

Tantangan utama dalam dunia Big Data tingkat lokal adalah batasan kapasitas perangkat keras (terutama memori RAM). Ketika dihadapkan pada berkas log data mentah perilaku konsumen (clickstream) berukuran 14 GB dengan total lebih dari 110 juta baris data, penggunaan pustaka konvensional seperti Pandas murni dipastikan akan memicu terjadinya Out-of-Memory (OOM) Error atau pembekuan sistem (force close).

Proyek ini berhasil membangun sebuah Modern Data Stack (MDS) lokal yang tangguh, efisien, dan responsif tanpa bergantung pada infrastruktur komputasi awan (Cloud Data Warehouse) yang mahal. Menggabungkan efisiensi query berbasis tabel kolom dari DuckDB serta kecepatan transformasi paralel dari Polars, proyek ini mampu menyaring, melakukan agregasi kompleks, dan memvisualisasikan data makro e-commerce tersebut ke dalam dasbor analitik Streamlit secara real-time dengan waktu pemrosesan di bawah satu menit.

2. Desain Arsitektur & Pemilihan Teknologi

Arsitektur pipa data dirancang dengan memisahkan fungsi komputasi berat (mesin basis data) dari fungsi manajemen visual data (lapangan presentasi). Diagram di bawah ini mengilustrasikan aliran data serta interaksi antar komponen sistem secara nyata:



Gambar 2.1: Aliran Interaksi Sinkronisasi Komponen Modern Data Stack Lokal

Berdasarkan skema arsitektur di atas, Streamlit bertindak sebagai pusat kendali utama (Interactive Web UI) yang secara simultan dapat mengirimkan instruksi query langsung ke DuckDB untuk penarikan data cepat, mengelola dataframe besar yang diproses secara paralel oleh Polars, serta meneruskan hasilnya ke Plotly Engine untuk memicu visualisasi yang dinamis.

Komponen	Teknologi	Keunggulan Arsitektur & Alasan Pemilihan
OLAP Query Engine	DuckDB	Embedded database khusus untuk pemrosesan analitik. Mendukung eksekusi tervektorisasi, penanganan data langsung di disk (Out-of-Core), serta integrasi SQL deklaratif yang sangat cepat tanpa server tambahan.
Data Transformation	Polars DataFrame	Ditulis menggunakan bahasa tingkat rendah (Rust). Mendukung performa multi-threading murni yang mengeksplorasi seluruh core CPU secara paralel guna menerima data matang dari DuckDB dengan konsumsi RAM minimal.
User Interface	Streamlit & Plotly	Mempercepat deployment aplikasi web berbasis Python secara interaktif. Rendering visualisasi Plotly berjalan mulus berkat suplai data yang ringkas dari hasil agregasi hulu.

3. Solusi Rekayasa Data (Big Data Engineering Highlights)

Untuk memastikan laptop lokal mampu mengolah data berskala puluhan gigabyte secara stabil, tiga pilar teknik optimisasi basis data diterapkan penuh:

A. Filter & Projection Pushdown

DuckDB secara cerdas tidak memuat keseluruhan berkas 14 GB ke memori. Ketika pengguna memilih filter bulan atau merek tertentu, mesin database hanya memindai (scan) dan memproyeksikan kolom yang dibutuhkan (price, event_type, brand, event_time). Hal ini memangkas ukuran operasional data aktif dari belasan gigabyte menjadi hanya beberapa ratus megabyte saja.

B. Out-of-Core Processing (Spilling to Disk)

Saat melakukan agregasi penuh lintas bulan (Oktober dan November sekaligus) yang menampung 110 juta baris, kapasitas RAM fisik laptop menemui ambang batasnya. Alih-alih mengalami kerusakan sistem (crash), DuckDB secara otomatis mengaktifkan mekanisme penyaluran memori sementara ke SSD (Spilling to Disk). Proses eksekusi melambat secara wajar, namun aplikasi dijamin tetap berjalan aman hingga tuntas.

C. Eliminasi Python Looping via Vektorisasi SQL

Seluruh kalkulasi berat (perhitungan konsumen unik `DISTINCT user_id` dan perangkaian metrik konversi) diproses melalui sintaks SQL deklaratif teroptimasi. Operasi pencarian merek terpopuler yang biasanya memakan waktu berjam-jam menggunakan perulangan (looping) baris-per-baris Python murni, berhasil dipangkas menjadi hitungan detik berkat pemrosesan blok vektor berbasis CPU modern.

Bukti Validasi Lapangan (Real-Time Rendering):

Dalam pengujian riil melalui rekaman video sistem, transisi pemrosesan data tunggal (Oktober: ~42 juta baris) menuju penggabungan data penuh (Oktober & November: 110M+ baris) memicu loading spinner interaktif. Jeda rendering yang memakan waktu beberapa puluh detik ini merupakan representasi jujur dari aktifnya fitur Spilling to Disk demi menjaga kestabilan sistem tanpa mengalami interupsi crash.

4. Analisis Business Intelligence & Sales Funnel Insights

Melalui pemrosesan makro data ini, struktur perjalanan pengguna (User Journey) dipetakan ke dalam bentuk Sales Funnel Analysis untuk mengekstrak titik-titik kebocoran bisnis operasional:

Tahapan Funnel	Volume Perilaku	Rasio Konversi	Evaluasi & Rekomendasi Strategis
1. Product Views	1,85 Juta Sesi	100%	Menunjukkan performa pemasaran digital di hulu (top-of-funnel) sangat berhasil mendatangkan ketertarikan awal pelanggan.
2. Add To Cart	83,84 Ribu Sesi	4.53%	 Bottleneck Kritis (Drop-off 95.47%). Konsumen hanya melihat tanpa memasukkan produk ke keranjang. Diperlukan evaluasi UI/UX halaman, penyesuaian harga kompetitif, serta penyertaan social proof (ulasan pengguna).
3. Completed Purchase	30,43 Ribu Sesi	1.65%	Tingkat konversi akhir dari lalu lintas awal. Rasio konversi dari Keranjang menuju Pembelian tergolong sehat (~36%), menandakan proses transaksi/checkout tidak bermasalah, kebocoran murni ada di tahap minat beli produk.

5. Struktur Kode & Manajemen Repositori

Sesuai standar industri Software Engineering, repositori kode diatur secara minimalis dan modular. Berkas data mentah 14 GB diisolasi secara penuh agar tidak membebani server pelacak versi:

```
# Berkas konfigurasi keamanan lokal (.gitignore)
```

```
# Mengabaikan database lokal dan file CSV raksasa dari push GitHub
*.csv
*.db
*.sqlite
data/
```

Implementasi ini membuktikan pemahaman mendalam tentang siklus hidup pengembangan perangkat lunak, di mana fokus repositori bertindak sebagai arsitektur logika sistem kodingan, sedangkan aset visualisasi disajikan secara ringkas dalam dokumentasi yang informatif.

6. Kesimpulan & Nilai Profesional

Proyek ini menegaskan bahwa esensi dari seorang Data Analyst & Automation Specialist bukan sekadar mahir merancang grafik visual yang indah, miris melainkan memiliki kapabilitas arsitektur untuk membangun pipa data yang efisien, tangguh, serta mampu mengekstrak nilai bisnis dari data berskala raksasa di bawah keterbatasan infrastruktur.