

Instacart Enterprise Market Basket & Operational Intelligence Dashboard



PROJECT AUTHOR

Daffa Farros Azhari

Data Analyst & Automation Specialist

Dataset: 32.4M+ Rows

Python

Streamlit

DuckDB

Polars

Plotly


Executive Summary

Proyek ini bertujuan untuk membangun **Enterprise-Grade Executive BI Dashboard** berkinerja tinggi yang mampu mengolah dan memvisualisasikan lebih dari **32,4 juta baris data transaksi Instacart** secara *real-time* tanpa lag (*sub-second latency*).

Dengan mengombinasikan **DuckDB** sebagai *SQL Join Engine*, **Polars** untuk *data frame manipulation*, serta **Streamlit & Plotly** sebagai *frontend interactive layer*, sistem ini menyajikan analisis hierarkis (*Pyramid Data Storytelling Model*) untuk membantu eksekutif mengambil keputusan strategis di bidang *Supply Chain*, *Demand Forecasting*, dan *Customer Retention*.

1. Data Schema & Relational Model (ERD)

Arsitektur database dirancang menggunakan **Star Schema** dengan tabel `order_products__prior` bertindak sebagai *Fact Table* utama. Relasi antar-tabel dihubungkan secara efisien melalui *foreign key constraint* menggunakan klausa **INNER JOIN** pada DuckDB.



Gambar 1: Relational Data Schema & SQL JOIN Logic (Star Schema)


Detail Structure & Relational Keys:

- **Fact Table (order_products__prior):** Menyimpan granularity tingkat item transaksi (32.4M+ baris).
 - **order_id** (FK → orders.order_id)
 - **product_id** (FK → products.product_id)
 - **add_to_cart_order** (Urutan item masuk keranjang)
 - **reordered** (Indikator 0 = First-Time Order, 1 = Repeat Order)
- **Dimension: Orders (orders):**
 - **order_id** (PK)
 - **order_dow** (Day of Week: 0 = Sunday, 6 = Saturday)
 - **order_hour_of_day** (Operating Hours: 0 - 23)
- **Dimension: Products (products):**
 - **product_id** (PK)
 - **product_name** (Nama Produk)
 - **department_id** (FK → departments.department_id)
 - **aisle_id** (FK → aisles.aisle_id)

- **Dimension: Categories (departments & aisles):**
 - department_id / aisle_id (PK)
 - department / aisle (Nama Kategori / Lokasi Rak)

2. End-to-End System Pipeline Architecture

Alur pemrosesan data dirancang dalam **5 tahap sistematis** untuk menjamin *scalability, data integrity*, dan kecepatan pemrosesan data berukuran besar.



3. Tahapan Pengolahan Data (Step-by-Step Breakdown)

Stage 1: Data Sources & Ingestion

Memuat 4 berkas CSV inti (`orders.csv` , `order_products__prior.csv` , `products.csv` , `departments.csv`). Dua file sekunder diabaikan pada agregasi utama untuk mengoptimalkan memori runtime tanpa mengurangi akurasi analisis makro.

Stage 2: Relations & SQL Join Engine (DuckDB)

Menggunakan **DuckDB** untuk mengeksekusi *in-memory JOIN* berkecepatan tinggi langsung di atas berkas CSV tanpa perlu mengimpor data ke RDBMS tradisional. Menggunakan fungsi `TRY_CAST()` pada tipe data integer untuk mencegah query error akibat *dirty values*.

Stage 3: Dynamic Filter Layer (5 Interactive Slicers)

Seluruh visualisasi terhubung secara dinamis ke 5 *slicer* di sidebar Streamlit:

- 1. **Transaction Day:** Filter hari transaksi (`WHERE order_dow = X`).
- 2. **Department Filter:** Filter multi-kategori (`WHERE department IN (...)`).
- 3. **Operating Hours:** Filter rentang jam operasional (`WHERE order_hour_of_day BETWEEN A AND B`).
- 4. **Minimum Basket Size:** Eliminasi transaksi kecil (`HAVING COUNT(product_id) >= N`).
- 5. **Customer Type:** Segmentasi pelanggan (`WHERE reordered = 0 OR 1`).

Stage 4: Aggregation Pipeline (Polars DataFrames)

Hasil query SQL dari DuckDB dikonversi langsung ke **Polars DataFrame** untuk proses agregasi tingkat lanjut (seperti matriks pivot heatmap, pemeringkatan Top N, dan kalkulasi rasio retensi) dengan efisiensi CPU dan RAM yang maksimal.

Stage 5: Executive Dashboard Frontend (Streamlit + Plotly)

Level Dashboard	Fokus Analisis	Komponen Visual	Business Value
Level 1	Executive KPIs	4 Metric Cards	Ringkasan performa utama: <i>Total Orders</i> , <i>Total Items Sold</i> , <i>Reorder Retention %</i> , dan <i>Avg Basket Size</i> .

Level Dashboard	Fokus Analisis	Komponen Visual	Business Value
Level 2	Macro Demand Patterns	- Heatmap (Day vs Hour) - Top 6 Departments Bar Chart	Identifikasi jam sibuk operasional (<i>peak hours</i>) dan kontribusi volume kategori terbesar.
Level 3	Tactical & Live Operations	- Retention Line Chart - Stacked Bar Chart (Loyalty) - Live Stream Cards	Analisis perilaku keranjang belanja, proporsi <i>Repeat</i> vs <i>First-Time Customer</i> , serta simulasi feed gudang.

4. Key Business Insights & Actionable Takeaways

1. Operational Peak Hours (Warehouse Staffing)

Insight: Kepadatan transaksi tertinggi (*peak hours*) terjadi secara konsisten pada **Hari Minggu & Senin pukul 10:00 - 15:00**.

Action: Tim operasional gudang wajib menambah alokasi tenaga *picker/packer* pada slot jam tersebut untuk mencegah *bottleneck* pengiriman.

2. Department Volume Drivers

Insight: Kategori **Produce (Sayur & Buah)** dan **Dairy Eggs** menyumbang lebih dari **50% total volume penjualan toko**.

Action: Penataan *inventory* kategori ini harus ditempatkan pada lokasi rak yang paling mudah dijangkau (*fast-moving aisle*).

3. Add-to-Cart Sequence Retention Hook

Insight: Produk yang dimasukkan pelanggan pada **urutan ke-1 hingga ke-3** di keranjang memiliki rasio pembelian ulang (*repeat order rate*) hingga **68%**.

Action: Pemasangan fitur *recommendation engine* atau promosi produk rutin pada slot awal aplikasi dapat meningkatkan *customer lifetime value*.

5. Technical Stack Summary

- **Frontend:** Streamlit (Custom CSS, High-Contrast Forest Green Theme)
- **Visualizations:** Plotly Express & Plotly Graph Objects
- **Query Engine:** DuckDB (OLAP Database Engine)
- **Data Processing:** Polars DataFrame
- **Caching Mechanism:** `@st.cache_data` (Sub-second query response time)